从 DDPM 到 DDIM：核心推导汇报

基于中文讲解材料与原始论文整理

2026 年 3 月 6 日

摘要

本文按照“为什么 DDPM 采样慢”“DDIM 究竟改了什么”“核心更新式如何推出来”的顺序，对 DDIM 做一份偏推导型的汇报。按照要求，预备知识部分尽量压缩，只保留最少记号。全文重点强调两件事：其一，DDIM 不是换了训练目标，而是抓住了 DDPM 目标只依赖边缘分布 $q(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ 的事实，从而把马尔可夫前向过程推广成一族非马尔可夫过程；其二，DDIM 的采样式本质上是“预测干净样本 $\hat{\boldsymbol{x}}_0$ + 沿当前噪声方向推进 + 可选随机噪声”的三项分解，这正是它能在不重训模型的前提下显著减少采样步数的原因。

目录

1 汇报目标与最少记号 **2**

2 DDPM：问题出在什么地方 **2**

2.1 前向加噪与闭式采样 2

2.2 反向去噪与 DDPM 采样瓶颈 3

3 从 DDPM 到 DDIM：关键观察 **3**

3.1 核心观察：训练目标只依赖边缘，不依赖完整联合 3

3.2 DDIM 的突破口：构造非马尔可夫前向过程 4

4 DDIM 的核心推导 **4**

4.1 第一步：由噪声预测得到干净样本估计 4

4.2 第二步：用预测的干净样本替换原始样本 4

4.3 第三步：如何理解这条更新式 5

4.4 第四步：为什么训练目标不用改 5

5 DDPM 与 DDIM 的对应关系 **5**

5.1 DDPM 是 DDIM 家族中的一个特例 5

5.2 DDIM 是确定性极限 6

6 为什么 DDIM 可以更快 **6**
6.1 跳步采样的合法性 6
6.2 用 eta 参数控制随机性 6

7 DDPM 与 DDIM 的差异总结 **7**

8 补充：ODE 视角为什么重要 **7**

9 结论 **7**

1 汇报目标与最少记号

本文默认读者已经知道高斯分布、变分下界与基本神经网络训练，不再展开这些背景。为避免记号混乱，全文采用 DDPM 社区更常见的一套记法：

$$\alpha_t = 1 - \beta_t, \tag{1}$$

$$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s, \tag{2}$$

$$q(\boldsymbol{x}_t \mid \boldsymbol{x}_0) = \mathcal{N}\big(\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0,\, (1-\bar{\alpha}_t)\mathbf{I}\big)\,. \tag{3}$$

其中 $\boldsymbol{x}_0$ 是真实数据，$\boldsymbol{x}_t$ 是第 t 步加噪后的变量，$\boldsymbol{x}_T$ 接近标准高斯。需要特别说明的是：**DDIM 原论文中很多地方把本文的 $\bar{\alpha}_t$ 直接记成 α_t**。为了和多数中文资料保持一致，本文仍使用 $\bar{\alpha}_t$ 写法。

2 DDPM：问题出在什么地方

2.1 前向加噪与闭式采样

DDPM 的前向过程是固定的马尔可夫链：

$$q(\boldsymbol{x}_t \mid \boldsymbol{x}_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}\boldsymbol{x}_{t-1},\, \beta_t\mathbf{I})\,. \tag{4}$$

把它连乘起来，可以得到任意时刻的闭式边缘分布

$$q(\boldsymbol{x}_t \mid \boldsymbol{x}_0) = \mathcal{N}\big(\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0,\, (1-\bar{\alpha}_t)\mathbf{I}\big)\,, \tag{5}$$

因此可以直接写成重参数化形式

$$\boldsymbol{x}_t = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}). \tag{6}$$

这一步很关键，因为后面 DDPM 和 DDIM 训练时都只会反复用到这个边缘分布，而不是完整的联合分布。

2.2 反向去噪与 DDPM 采样瓶颈

DDPM 要学的是反向条件分布 $p_\theta(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t)$。在变分推导里，一个核心量是前向后验

$$q(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, \boldsymbol{x}_0) = \mathcal{N}\Big(\boldsymbol{x}_{t-1};\, \tilde{\boldsymbol{\mu}}_t(\boldsymbol{x}_t, \boldsymbol{x}_0),\, \tilde{\beta}_t \mathbf{I}\Big), \tag{7}$$

其中

$$\tilde{\boldsymbol{\mu}}_t(\boldsymbol{x}_t, \boldsymbol{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}\boldsymbol{x}_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\boldsymbol{x}_t, \tag{8}$$

$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t. \tag{9}$$

因此 DDPM 的单步采样可以理解为：先根据网络预测出当前噪声或均值，再按高斯分布从 $\boldsymbol{x}_t$ 采出 $\boldsymbol{x}_{t-1}$。

问题也恰恰出在这里。由于这个反向链是逐步执行的，若训练时用了 $T = 1000$ 步，那么采样时通常也要跑近似数量级的网络前向。于是：

- 训练并不算特别难；
- 但生成一张图要执行很多次 U-Net；
- 这使 DDPM 的主要成本集中在**采样阶段**，而不是训练阶段。

因此，从 DDPM 过渡到 DDIM 的真正动机，不是“把目标函数换掉”，而是“在不破坏训练目标的前提下，重新定义一条更高效的生成路径”。

3 从 DDPM 到 DDIM：关键观察

3.1 核心观察：训练目标只依赖边缘，不依赖完整联合

DDIM 论文最重要的一步，不是直接改采样公式，而是先重新审视 DDPM 的训练目标。DDPM 可以写成噪声预测目标

$$L_{\text{simple}} = \mathbb{E}_{t,\boldsymbol{x}_0,\boldsymbol{\epsilon}}\left[\left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\big(\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon},\, t\big)\right\|_2^2\right]. \tag{10}$$

注意这里出现的随机变量构造只依赖于 $q(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$，也就是

$$\boldsymbol{x}_t = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}.$$

它并没有直接要求前向过程必须是某个固定的马尔可夫链。只要新的前向过程仍然满足相同的边缘分布 $q(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$，那么训练时看到的噪声预测问题就不变。

3.2 DDIM 的突破口：构造非马尔可夫前向过程

于是 DDIM 引入一族由 σ_t 参数化的非马尔可夫前向/后验结构：

$$q_\sigma(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, \boldsymbol{x}_0) = \mathcal{N}\left(\sqrt{\bar{\alpha}_{t-1}}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}\,\frac{\boldsymbol{x}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0}{\sqrt{1-\bar{\alpha}_t}}, \sigma_t^2\mathbf{I}\right). \tag{11}$$

这看上去只是“重新写了一个条件高斯”，但含义非常深：

- 当 σ_t 取特定值时，它退化回 DDPM 对应的马尔可夫情形；
- 当 $\sigma_t \to 0$ 时，条件分布会变成确定性映射；
- 更重要的是，这个新家族**仍然保持相同的边缘分布** $q_\sigma(\boldsymbol{x}_t \mid \boldsymbol{x}_0) = q(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$。

这一步说明：**DDPM 对应的前向链不是唯一选择。**只要边缘保持不变，就可以把训练好的噪声预测网络用于另一族生成过程。

4 DDIM 的核心推导

4.1 第一步：由噪声预测得到干净样本估计

因为

$$\boldsymbol{x}_t = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}, \tag{12}$$

所以一旦网络预测出噪声 $\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t)$，就能反推出一个“去噪后的样本估计”：

$$\hat{\boldsymbol{x}}_0 := f_\theta(\boldsymbol{x}_t, t) = \frac{\boldsymbol{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t)}{\sqrt{\bar{\alpha}_t}}. \tag{13}$$

这一式子极其重要。DDPM 中网络通常被解释为“预测噪声”；而在 DDIM 推导里，更自然的理解是：**先用噪声预测恢复 $\hat{\boldsymbol{x}}_0$，再由 $\hat{\boldsymbol{x}}_0$ 决定下一步去哪。**

4.2 第二步：用预测的干净样本替换原始样本

把式 (13) 代入式 (11) 中的 $\boldsymbol{x}_0$，就得到 DDIM 的生成分布

$$p_\theta(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t) = q_\sigma(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, \hat{\boldsymbol{x}}_0). \tag{14}$$

再利用

$$\frac{\boldsymbol{x}_t - \sqrt{\bar{\alpha}_t}\hat{\boldsymbol{x}}_0}{\sqrt{1-\bar{\alpha}_t}} = \boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t), \tag{15}$$

可以把均值显式展开成三项分解：

$$\boldsymbol{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\hat{\boldsymbol{x}}_0 + \sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}\,\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t) + \sigma_t\boldsymbol{z}, \qquad \boldsymbol{z} \sim \mathcal{N}(0, \mathbf{I}). \tag{16}$$

这就是 DDIM 最核心的一条更新式。

4.3 第三步：如何理解这条更新式

式 (16) 可以拆成三个语义明确的部分：

1. $\sqrt{\bar{\alpha}_{t-1}}\hat{\boldsymbol{x}}_0$：把当前状态拉回“预测的干净样本”方向，是**信号恢复项**；
2. $\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}\,\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t,t)$：保留与当前 $\boldsymbol{x}_t$ 一致的噪声方向，是**朝向当前轨迹的方向项**；
3. $\sigma_t\boldsymbol{z}$：额外注入新的随机性，是**随机扰动项**。

因此，DDIM 不是简单地“删掉噪声”，而是把一步更新明确分成“恢复内容 + 沿当前轨迹推进 + 是否再加随机性”三件事。这个分解正是 DDPM 到 DDIM 的结构性变化。

4.4 第四步：为什么训练目标不用改

真正支撑 DDIM 成立的不是更新式本身，而是下面这个等价关系。对任意 $t>1$，考虑

$$\mathrm{KL}\Big(q_\sigma(\boldsymbol{x}_{t-1}\mid\boldsymbol{x}_t,\boldsymbol{x}_0)\,\|\,q_\sigma(\boldsymbol{x}_{t-1}\mid\boldsymbol{x}_t,\hat{\boldsymbol{x}}_0)\Big). \tag{17}$$

由于二者是方差相同的高斯分布，上式等价于均值差的平方，即

$$\mathrm{KL}\propto\frac{\|\boldsymbol{x}_0-\hat{\boldsymbol{x}}_0\|_2^2}{2\sigma_t^2}. \tag{18}$$

再把 $\hat{\boldsymbol{x}}_0$ 用式 (13) 代入，就得到

$$\|\boldsymbol{x}_0-\hat{\boldsymbol{x}}_0\|_2^2=\frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}\,\|\boldsymbol{\epsilon}-\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t,t)\|_2^2, \tag{19}$$

于是整个变分目标最终可化成

$$J_\sigma(\boldsymbol{\epsilon}_\theta)\equiv\sum_{t=1}^{T}\gamma_t\mathbb{E}\big[\|\boldsymbol{\epsilon}-\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t,t)\|_2^2\big]=L_\gamma(\boldsymbol{\epsilon}_\theta), \tag{20}$$

这里只是权重 γ_t 随 σ_t 变化，但目标形式仍然是同一个噪声预测问题。于是：

- **训练网络这件事没变**；
- 变的只是**采样时选择哪一条反向轨迹**；
- 这就是 DDIM 能直接复用 DDPM 训练模型的根本原因。

5 DDPM 与 DDIM 的对应关系

5.1 DDPM 是 DDIM 家族中的一个特例

如果取

$$\sigma_t=\sqrt{\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}}\sqrt{1-\frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}}, \tag{21}$$

那么式 (16) 对应回 DDPM 的随机反向过程。换句话说，DDPM 并不是 DDIM 的对立面，而是 DDIM 这整个广义采样家族中的一个特例。

5.2 DDIM 是确定性极限

如果进一步令

$$\sigma_t = 0, \tag{22}$$

那么式 (16) 退化为

$$\boldsymbol{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\hat{\boldsymbol{x}}_0 + \sqrt{1-\bar{\alpha}_{t-1}}\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t), \tag{23}$$

不再注入新的随机噪声。此时一旦初始噪声 $\boldsymbol{x}_T$ 固定，整条采样轨迹就被唯一确定。这正是 DDIM 能做以下事情的原因：

- 用同一个 $\boldsymbol{x}_T$ 在不同步数下生成语义一致的样本；
- 在潜变量空间做更稳定的插值；
- 把采样过程解释为某个 ODE 的离散化。

6 为什么 DDIM 可以更快

6.1 跳步采样的合法性

既然训练目标只要求每个选中时刻的边缘分布保持不变，就没有必要真的按 $1, 2, \ldots, T$ 每一步都采样。DDIM 允许只在一个子序列

$$\tau = (\tau_1, \tau_2, \ldots, \tau_S), \qquad \tau_S = T, \quad S \ll T$$

上运行反向过程。此时只需把式 (16) 中的 t 换成相邻的 τ_i, τ_{i-1} 即可。

6.2 用 eta 参数控制随机性

论文常用下面的参数化统一 DDPM 与 DDIM：

$$\sigma_{\tau_i}(\eta) = \eta\sqrt{\frac{1-\bar{\alpha}_{\tau_{i-1}}}{1-\bar{\alpha}_{\tau_i}}}\sqrt{1-\frac{\bar{\alpha}_{\tau_i}}{\bar{\alpha}_{\tau_{i-1}}}}. \tag{24}$$

这里

- $\eta = 0$ 对应 DDIM；
- $\eta = 1$ 对应 DDPM 型随机性；
- 中间值表示在确定性与随机性之间折中。

因此“更快”并不是神奇地减少了训练量，而是采样时允许选更短的轨迹 S，例如从 1000 步降到 100、50 甚至更少，同时尽量保持生成质量。

7 DDPM 与 DDIM 的差异总结

对比维度	DDPM	DDIM
训练目标	噪声预测 / 变分目标	与 DDPM 相同，可直接复用
前向观点	固定马尔可夫扩散链	保持同边缘分布的一族非马尔可夫过程
单步更新	随机高斯反向采样	三项分解：$\hat{\boldsymbol{x}}_0$ 项 + 方向项 + 可选噪声项
随机性	固有随机	σ_t 或 η 可控，$\eta = 0$ 时确定性
速度来源	通常需完整长链	允许跳步采样，只走短轨迹 τ
潜变量一致性	同一 $\boldsymbol{x}_T$ 生成结果差异较大	同一 $\boldsymbol{x}_T$ 在不同轨迹下语义更一致

8 补充：ODE 视角为什么重要

DDIM 在 $\sigma_t = 0$ 时可以写成一种 Euler 离散格式。直观地说，这意味着 DDIM 的反向生成不是“不断重新抽样”的随机游走，而更像是在某条连续轨迹上做数值积分。这个观点的重要性在于：

- 它解释了为什么 DDIM 的生成在固定初值下具有一致性；
- 它说明 DDIM 更容易做反演、重构与潜空间操作；
- 它为后续的 ODE/SDE 统一视角、DPM-Solver 一类快速采样器提供了理论接口。

不过在本次汇报中，ODE 视角只需要作为结果理解即可；真正的主线仍然是前面那条：**同一训练目标，对应不止一条反向生成路径。**

9 结论

如果只用一句话概括 DDPM 到 DDIM 的过渡，那就是：

> DDIM 并没有重新训练一个新模型，而是证明了在保持 $q(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ 不变的前提下，可以把 DDPM 的马尔可夫前向过程推广为非马尔可夫过程；因此同一个噪声预测网络对应的不再只是 DDPM 那一条随机长链，而是一整个可调的生成过程家族。

对理解 DDIM，最值得记住的有三点：

1. DDPM 的训练目标只依赖边缘分布，所以前向联合分布有推广空间；
2. DDIM 的核心更新式是

$$\boldsymbol{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\hat{\boldsymbol{x}}_0 + \sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}\,\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t) + \sigma_t \boldsymbol{z};$$

3. 令 $\sigma_t = 0$ 后得到确定性采样，从而实现更少步数、更稳定的潜空间语义与更高的采样效率。

因此，**DDIM 的价值不在于把 DDPM 完全推翻，而在于把“扩散模型只能沿着一条随机长链采样”这件事打破了。**

参考文献

[1] Jonathan Ho, Ajay Jain, Pieter Abbeel. Denoising Diffusion Probabilistic Models. In *NeurIPS 2020*. arXiv:2006.11239. https://arxiv.org/abs/2006.11239

[2] Jiaming Song, Chenlin Meng, Stefano Ermon. Denoising Diffusion Implicit Models. In *ICLR 2021*. arXiv:2010.02502. https://arxiv.org/abs/2010.02502

[3] 《Stable Diffusion Model 核心概览》. 知乎专栏，文中给出了 DDPM 讲解文章与 Stable Diffusion 相关背景的串联。https://zhuanlan.zhihu.com/p/690723556

[4] 《扩散模型 DDPM 详解》. 知乎专栏，作为中文 DDPM 讲解材料引用于上文所示知乎文章中。https://zhuanlan.zhihu.com/p/624617160

[5] 《从 DDPM 到 DDIM》. 中文技术文章，适合作为从采样瓶颈到 DDIM 推导主线的辅助阅读。https://ewbang.com/community/article/details/1000281380.html